


# Lección 21:

## Árboles B



- Motivación
- Árboles B
- Estructura y propiedades de un árbol B
- Estructura de un árbol B
- Búsqueda
- Inserción
- Borrado



# Motivación



Supongamos que el catálogo de libros crece hasta un tamaño (10.000.000 de títulos) y que necesitamos hacer búsquedas por isbn, título y autor. El tamaño de estos tres índices en memoria sería:

- Índice primario: 10 (isbn) + 4 (posición) = 14 bytes
- Índice secundario título: 80 (título) + 10 (isbn) = 90 bytes
- Índice secundario autor: 40 (autor) + 10 (isbn) = 50 bytes

Total:  $10.000.000 * 154 \text{ bytes} = 1.4 \text{ Gb.}$

Un índice de este tamaño requiere un tiempo de carga importante y es poco manejable en memoria

# Árboles B



- Un árbol B es una estructura de ficheros que permite indexar un fichero **sin consumir memoria primaria** y con un rendimiento cercano al de un índice simple
- Son la base de las estructuras de ficheros empleadas por las bases de datos modernas


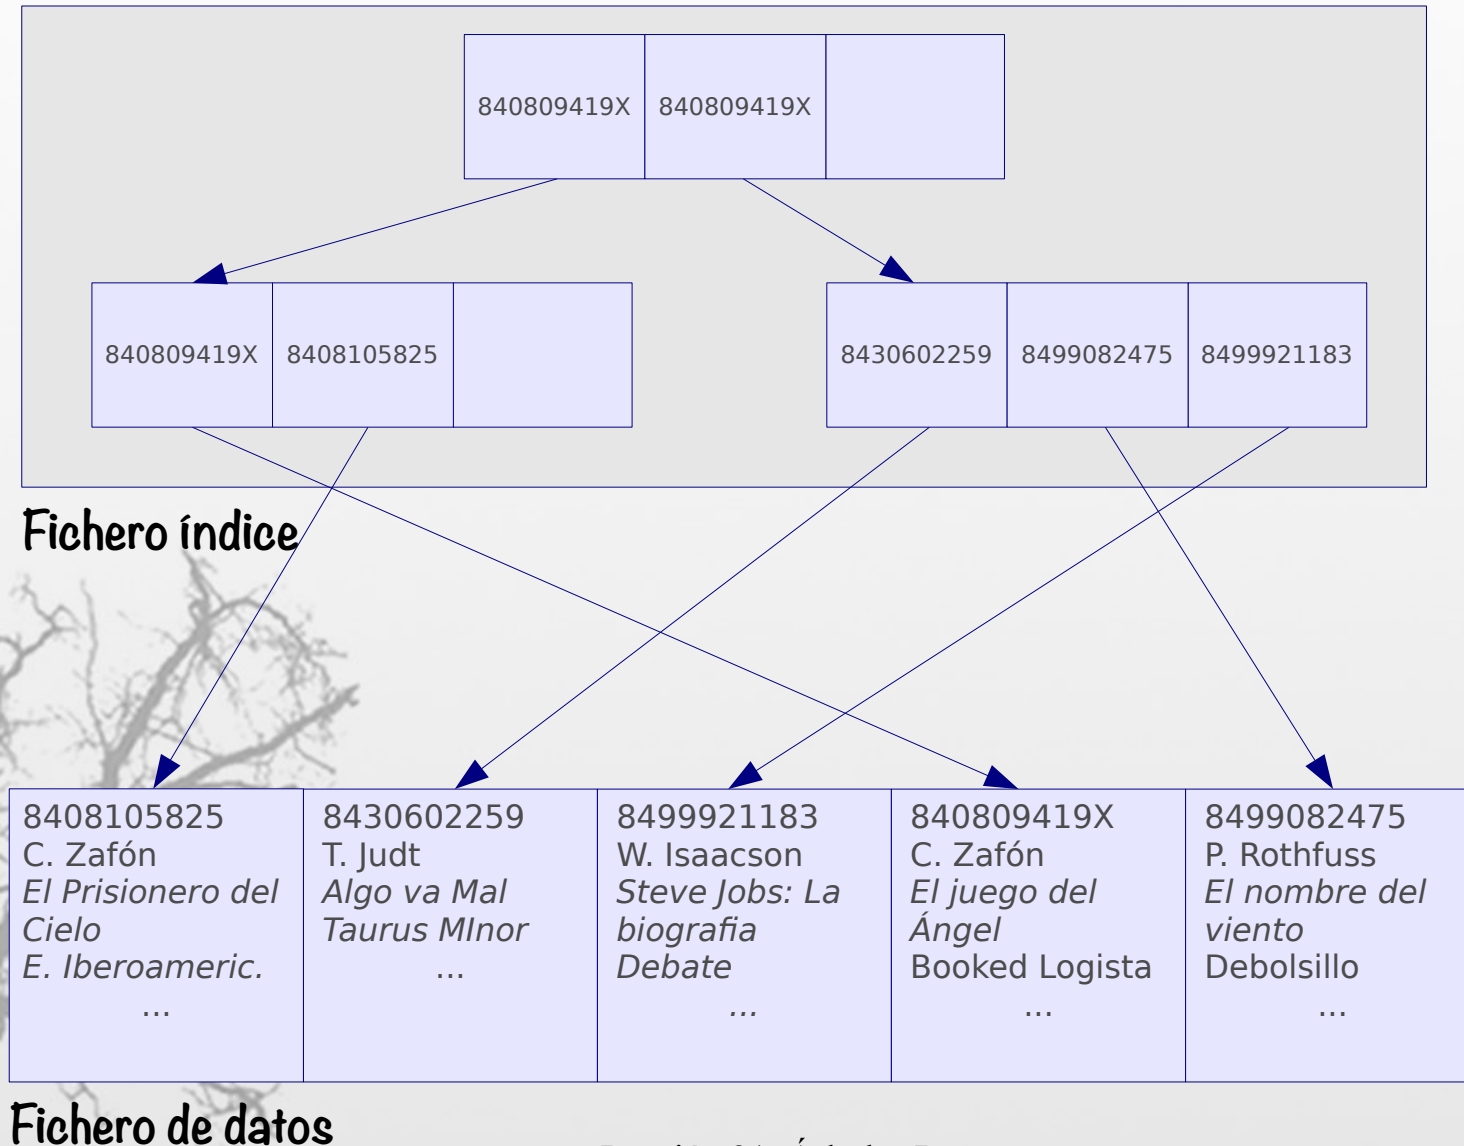


Ilustración original del artículo de Bayer y McCreight "Organization and Maintenance of Large Ordered Indexes" Acta Informática I (1972) donde se describieron por primera vez los árboles B.

# Propiedades de un árbol B

- Un árbol B guarda en cada nodo un conjunto de tuplas (clave, posición) donde posición es:
  - La posición de un nodo hijo en el fichero de índice (nodos interiores)
  - La posición de un registro en el fichero de datos (nodos hoja)
- Si  $m$  es el orden del árbol B, todos los nodos exceptuando la raíz tienen entre  $m/2$  y  $m$  tuplas (clave, posición)
- Las tuplas en un nodo están ordenadas por clave

# Estructura de un árbol B



# Estructura de un árbol B



- Propiedad: un árbol B es un árbol equilibrado, donde la profundidad de cada hoja es siempre la misma
- El último nivel es similar a un índice simple pero dividido en bloques (los nodos hoja) y residente en un fichero en lugar de memoria
- Cada nivel del árbol “indexa” los nodos del siguiente nivel usando la primera clave de cada uno
- El orden de un árbol B debe ser grande para sea eficiente a efectos prácticos (64 o superior)

# Búsqueda en árboles B



- Muy eficiente:  $O(\log_m n)$  siendo  $m$  el orden del árbol
  - Ejemplo: localiza un dato entre diez millones con 4 accesos a disco para  $m=256$
- Búsqueda del dato con clave  $x$ :
  1. Pasar el nodo raíz del árbol B a memoria
  2. Buscar la mayor clave del nodo tal que  $k \leq x$  y obtener su dirección  $d$ :
    - Si el nodo es una hoja, leer el registro en la posición  $d$  del fichero de datos
    - Si no, pasar a memoria el nodo del árbol en la posición  $d$  y continuar por el paso 2



# Inserción en árboles B



- También muy eficiente:  $O(\log_m n)$
- Inserción de la clave  $x$ :
  1. Localizar el nodo hoja que aloja la clave  $x$  mediante una búsqueda
  2. Insertar la clave  $x$  y la posición del registro en el fichero de datos
    - Si la clave cabe en el nodo pero cae en la primera posición, modificar la clave en el padre
    - Si la clave no cabe en el nodo, crear un nuevo nodo, repartir las claves e insertar en el que corresponda. Insertar la primera clave del nuevo nodo en el padre



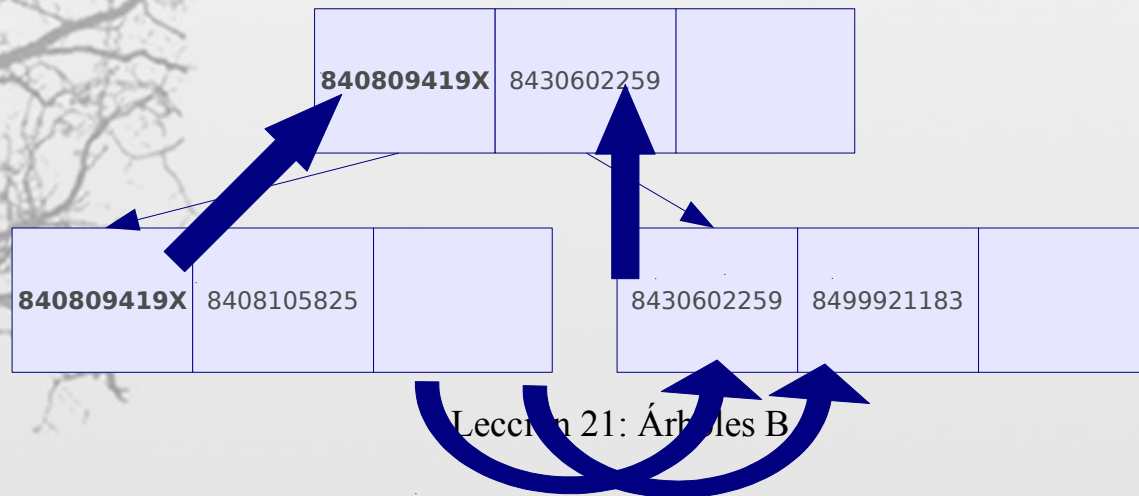
# Inserción en árboles B



Insertar 8408105825, 8430602259, 8499921183 (se omite el fichero de datos)

8408105825	8430602259	8499921183
------------	------------	------------


Insertar 840809419X. Se duplica el nodo, se redistribuyen las claves y se crea una nueva raíz




# Inserción en árboles B



Insertar 8499082475. Caso trivial



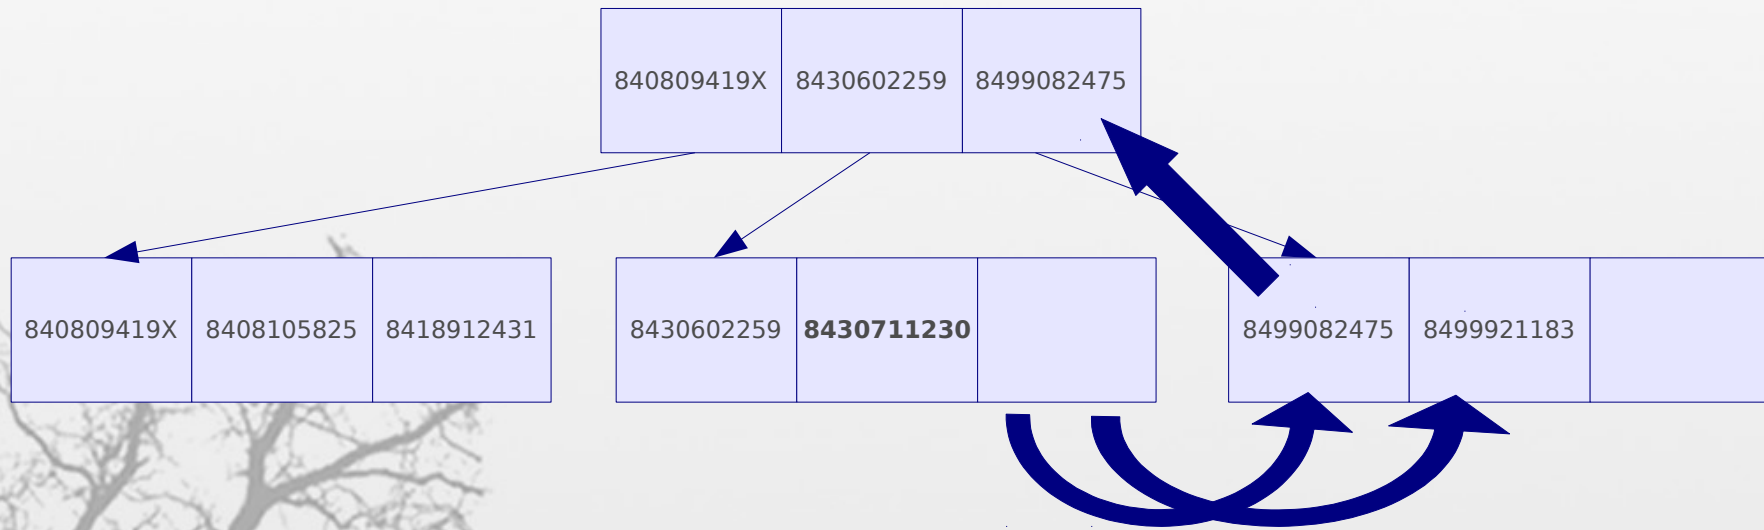
Insertar 8418912431. Caso trivial



# Inserción en árboles B



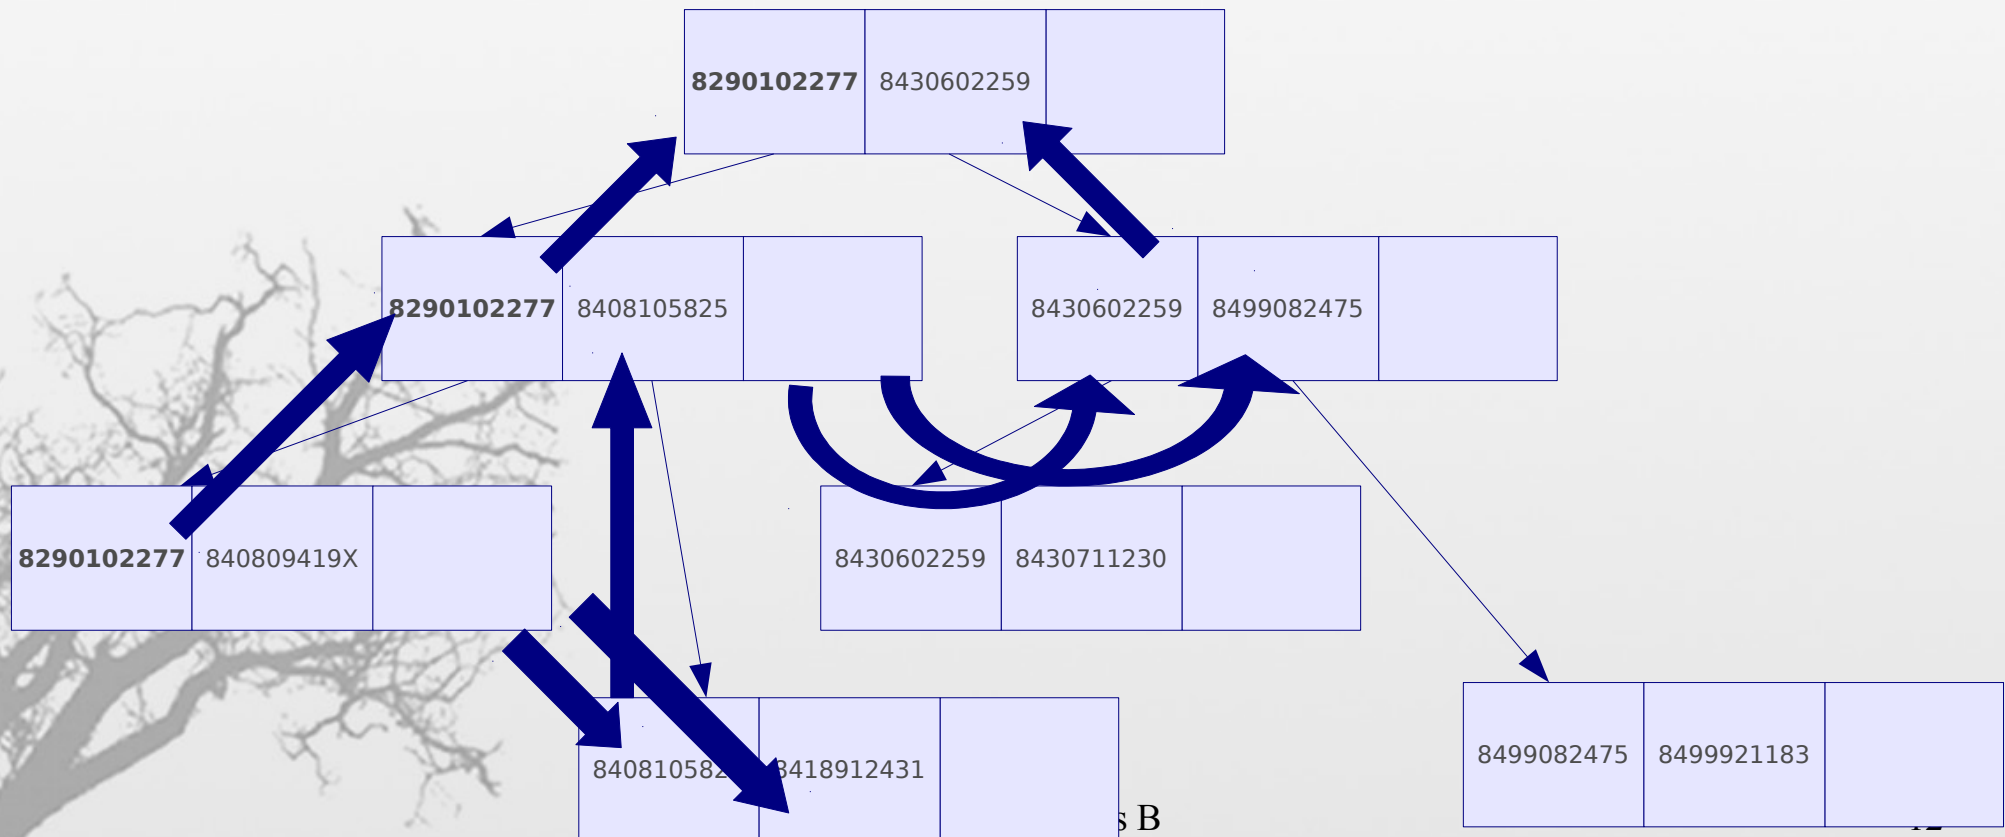
Insertar 8430711230. Nueva división y redistribución



# Inserción en árboles B



Insertar 8290102277. Se duplica y redistribuye. Al insertar la nueva clave en el padre se produce una nueva duplicación y redistribución, y se genera una nueva raíz



# Borrado en árboles B

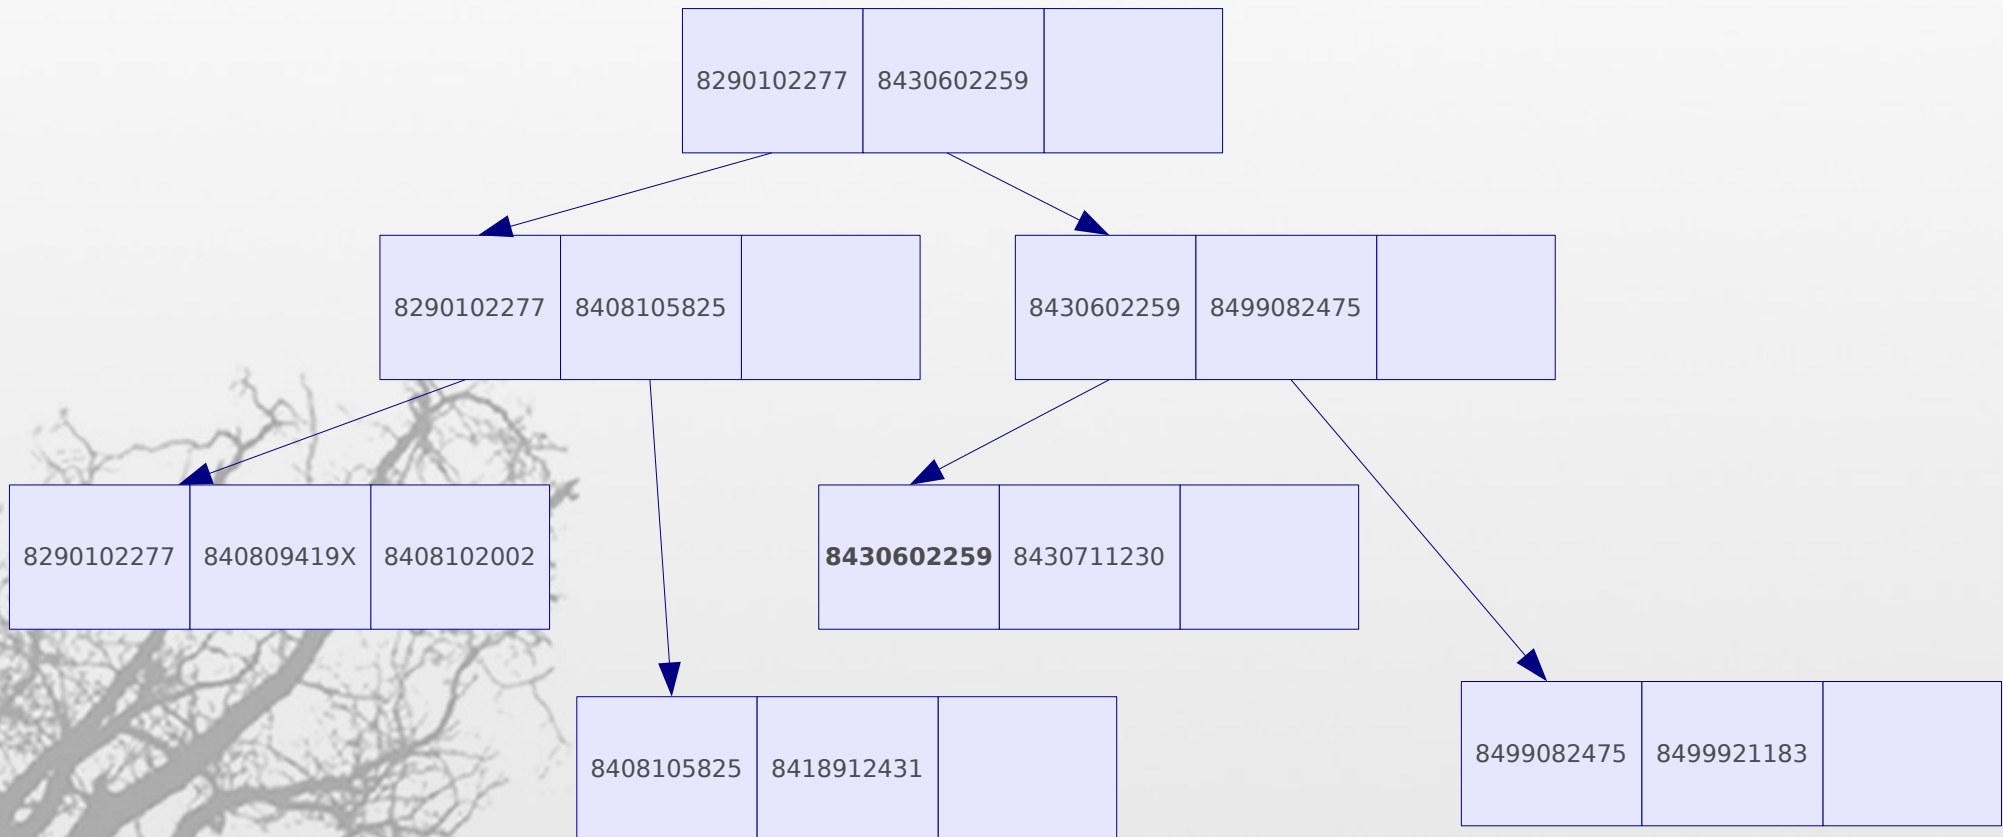


- Mismo orden:  $O(\log_m n)$
- Borrado de la clave  $x$ :
  1. Localizar el nodo hoja que aloja la clave  $x$  mediante una búsqueda
  2. Eliminar la clave  $x$  y la posición del registro del fichero de datos
    - Si se borra la primera clave, cambiar la clave en el nodo padre por la segunda clave del nodo
    - Si la ocupación cae por debajo del 50%:
      - Enviar las claves restantes a un nodo hermano y eliminar nodo. Eliminar la clave correspondiente en el padre
      - Si no es posible lo anterior, traer una clave de un nodo hermano para llegar al 50%

# Borrado en árboles B




Situación inicial. Borrado clave 843062259



# Borrado en árboles B



Se elimina la clave y la ocupación cae por debajo del 50%. Enviar la clave restante (8430711230) al nodo hermano derecha. Borrar el nodo y eliminar la clave en el padre. Ocurre la misma situación. Al final la antigua raíz es eliminada

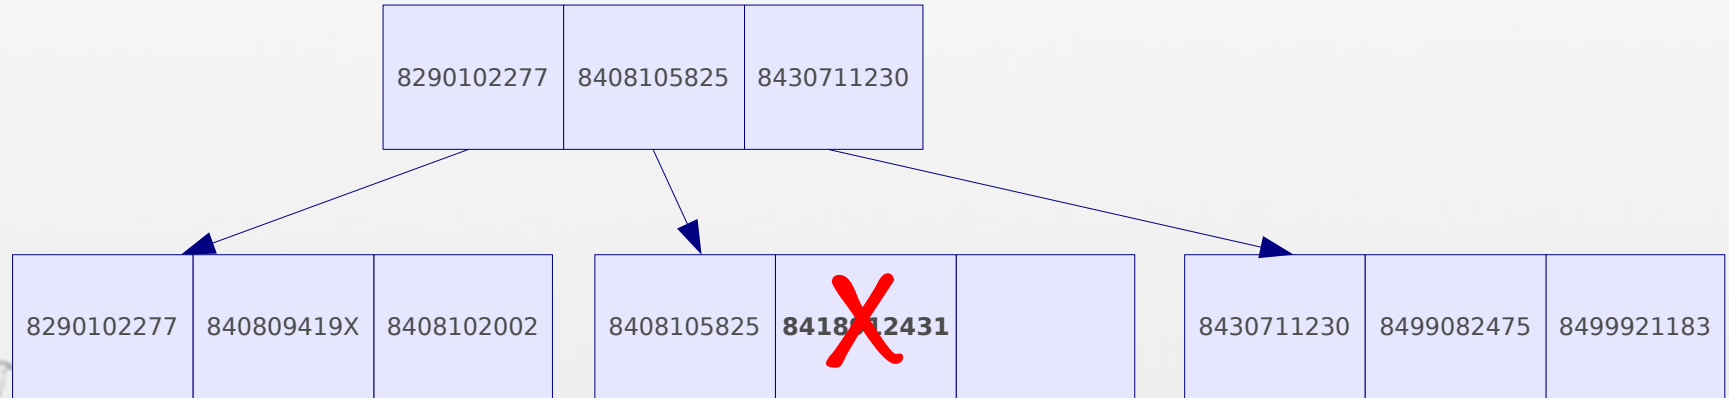




# Borrado en árboles B



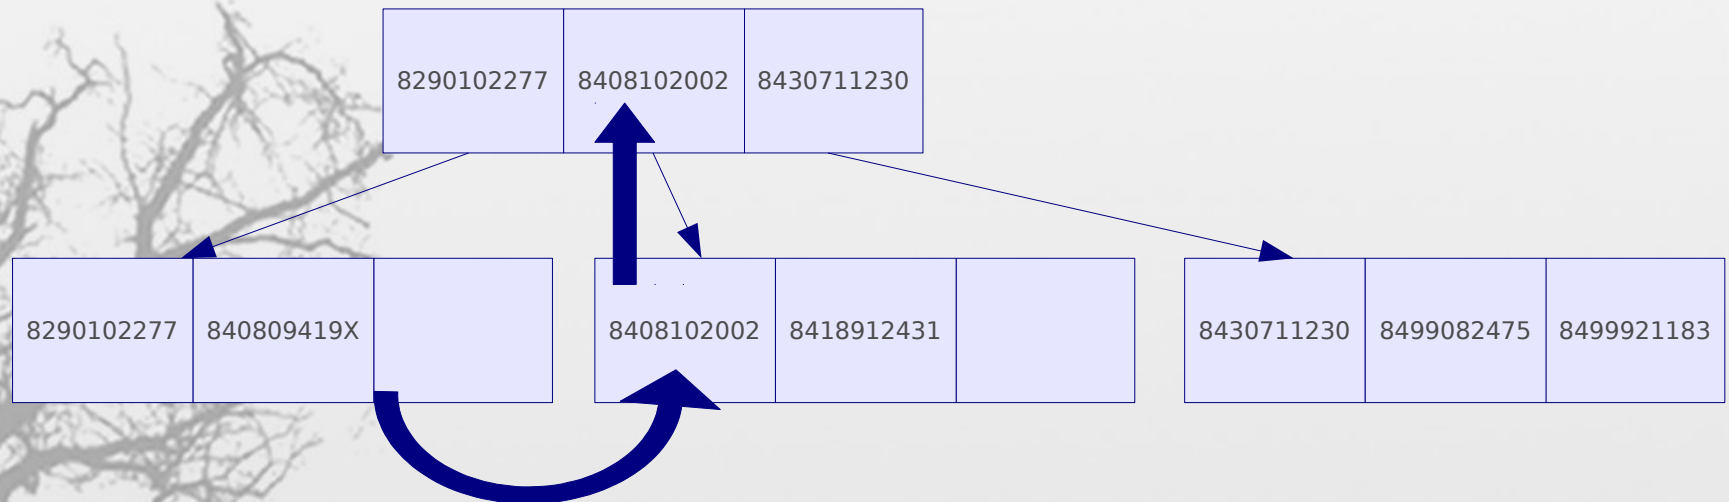
Estructura del árbol tras el borrado. Borrar 8418912431 a continuación.



# Borrado en árboles B



Se elimina la clave. La ocupación del nodo cae por debajo del 50% pero la clave restante (8412912431) no puede transferirse a los hermanos. Solución: traer la clave 8408102002 del hermano izquierdo. Actualizar el padre al modificar la primera clave del nodo.



# Conclusiones



- Un árbol B es un árbol  $m$ -ario (con  $m$  grande) equilibrado
- Se mantiene permanentemente en memoria secundaria por lo que puede crecer arbitrariamente
- Garantiza  $O(\log_m n)$  accesos al fichero índice en sus tres operaciones básicas, aunque lógicamente la inserción y el borrado son mucho más complejos que la búsqueda
- Es la estructura de ficheros que sirve como base para la implementación de los modernos sistemas de bases de datos